**Московский физико-технический институт**
**(национальный исследовательский университет)**

**Физтех-школа прикладной математики и информатики (ФПМИ)**

# Метод адаптивного забывания моделей на основе аппроксимации носителя совместного фазового распределения хаотических рядов

Математический практикум

**Выполнил:**
студент 2 курса ФПМИ
Сидорин Павел Дмитриевич

**Научный руководитель:**
Орлов Юрий Николаевич

Москва, 2026

# Содержание


**1 Введение и постановка задачи** **3**

1.1 Введение . . . 3

1.2 Постановка задачи . . . 3

1.3 Методологическая основа . . . 4

**2 Система Лоренца как генератор хаотического ряда** **4**

2.1 Уравнения системы . . . 4

2.2 Хаотический режим и аттрактор . . . 5

2.3 Моделирование нестационарности . . . 6

2.4 Численное интегрирование . . . 7

**3 Вложение временного ряда в фазовое пространство** **8**

3.1 Теорема Такенса . . . 8

3.2 Расширенное фазовое пространство . . . 8

3.3 Геометрический смысл для детектирования разладки . . . 9

**4 Выборочная плотность функции распределения (ВПФР)** **9**

4.1 Нормировка ряда . . . 9

4.2 Гистограммная оценка плотности . . . 9

4.3 Выбор оптимального числа бинов $M$ . . . 10

**5 Восстановление отображения через носитель ВПФР** **12**

5.1 Условное математическое ожидание как оценка $F$ . . . 12

5.2 Свойства восстановленного отображения . . . 12

5.3 Горизонт прогнозирования . . . 13

**6 Метрики расстояния между плотностями** **14**

6.1 Общая схема . . . 14

6.2 Норма $L_1$ (расстояние Колмогорова) . . . 14

6.3 Расстояние Хеллингера . . . 14

6.4 Дивергенция Кульбака–Лейблера . . . 14

6.5 Сравнение метрик . . . 15

**7 Согласованный уровень стационарности (СУС)** **16**

7.1 Проблема статистического шума . . . 16

7.2 Процедура бутстреп-калибровки . . . 16

7.3 Условие забывания . . . 17

**8 Алгоритм адаптивного забывания** **18**

8.1 Полная схема алгоритма . . . 18

**9 Экспериментальное детектирование разладки** **19**
9.1 Постановка эксперимента . . . . . 19
9.2 Изменение структуры ВПФР при разладке . . . . . 19
9.3 Детектирование момента разладки . . . . . 20
9.4 Адаптивное забывание . . . . . 20

**10 Сравнение с методом AR(2)** **21**
10.1 Линейная авторегрессия AR(2) . . . . . 21
10.2 Сравнение: многошаговый прогноз . . . . . 21
10.3 Поведение при разладке . . . . . 22

**11 Статистика задержки детекции** **23**
11.1 Случайный характер задержки . . . . . 23
11.2 Методология эксперимента . . . . . 23
11.3 Результаты . . . . . 23

**12 Обсуждение и выводы** **24**
12.1 Сводка результатов . . . . . 24
12.2 Преимущества метода . . . . . 24
12.3 Ограничения и направления развития . . . . . 24
12.4 Заключение . . . . . 25

# 1. Введение и постановка задачи

## 1.1. Введение

Реальные процессы крайне редко являются строго стационарными. Под *нестационарностью* понимается изменение вероятностных характеристик процесса со временем: могут меняться среднее, дисперсия, форма распределения и, в общем случае, сама $F$ ($x_n = F(x_{n-1}, \dots, x_{n-m})$) — порождающая функция отображения. Классические методы анализа временных рядов опираются на гипотезу стационарности, которая в нестационарных условиях нарушается, что приводит к нарастанию систематической ошибки прогноза.

Особую трудность представляют системы с детерминированным хаосом — динамические системы, траектории которых экспоненциально чувствительны к начальным условиям при том, что сам закон эволюции детерминирован. Такие системы порождают сигнал, внешне неотличимый от случайного: автокорреляционная функция быстро убывает до нуля, линейные модели дают прогноз не лучше наивного. Тем не менее их распределение в фазовом пространстве — *инвариантная мера* аттрактора ($\mu(A) = \lim\limits_{T\to\infty} \int\limits_0^T 1_{\{\vec{X}(t)\in A\}} dt$) — устойчиво и воспроизводимо при фиксированных параметрах. При изменении параметров эта мера деформируется, что является аналитически различимым сигналом разладки.

Таким образом, задача детектирования разладки хаотической системы естественно формулируется не в пространстве значений ряда, а в пространстве *распределений*.

## 1.2. Постановка задачи

Рассматривается нестационарный временной ряд $\{x_n\}_{n=1}^N$, предполагающий на каждом достаточно малом временном интервале нелинейную детерминированную динамику вида

$$x_n = F(x_{n-1},\, x_{n-2}) + \xi_n, \tag{1}$$

где $F\colon \mathbb{R}^2 \to \mathbb{R}$ — неизвестная функция отображения, $\xi_n$ — малый стохастический шум с нулевым средним. Вследствие нестационарности функция $F$ (или её параметры) может изменяться в некоторый момент $t_0$ — *момент разладки*.

Настоящая работа преследует три взаимосвязанные цели.

1. **Непараметрическое восстановление отображения $F$.** Восстановить функцию $F$ из данных через геометрию носителя совместного

распределения в расширенном фазовом пространстве без каких-либо предположений о её виде.

2. **Детектирование момента разладки.** Определить момент $t_0$, в который структура $F$ изменилась, путём сравнения *текущей* и *эталонной* плотностей распределения с помощью метрик расстояния.

3. **Адаптивное забывание.** При превышении расстоянием статистически обоснованного порога — *согласованного уровня стационарности* (СУС) — «забыть» накопленную модель и инициализировать новую эталонную плотность, адаптировав модель к изменившемуся режиму в автоматическом режиме.

## 1.3. Методологическая основа

Предлагаемый метод опирается на *кинетическую теорию временных рядов* [1]. Кинетический подход, рассматривает *эволюцию* самой выборочной плотности функции распределения (ВПФР) со временем.

В отличие от авторегрессионных методов, которые оценивают параметры линейной модели, предлагаемый подход изучает *геометрию носителя* инвариантной меры аттрактора. Эта геометрия инвариантна относительно хаотических флуктуаций отдельной траектории (что обеспечивает устойчивость оценок) и при этом чувствительна к изменению параметров системы (что обеспечивает детектируемость разладки). Именно это сочетание свойств делает метод применимым к хаотическим рядам.

Общая схема алгоритма:

$$\{x_n\} \xrightarrow{\text{вложение Такенса}} \vec{z}_n \in [0,1]^3 \xrightarrow{\text{гистограмма}} \hat{f}(i,j,k) \xrightarrow{L_1 > \varepsilon_{\text{СУС}}} \text{сброс модели.}$$

# 2. Система Лоренца как генератор хаотического ряда

## 2.1. Уравнения системы

Система Лоренца [2] — трёхмерная автономная система обыкновенных дифференциальных уравнений:

$$\begin{cases} \dot{x} = \sigma(y - x), \\ \dot{y} = x(\rho - z) - y, \\ \dot{z} = xy - \beta z, \end{cases} \tag{2}$$

где $\sigma > 0$ — число Прандтля (отношение кинематической вязкости к температуропроводности), $\rho > 0$ — число Рэлея (мера разности температур между нижней и верхней границами слоя), $\beta > 0$ — геометрический параметр. Уравнения (2) зависят от трёх начальных условий $(x_0, y_0, z_0)$ и трёх параметров $(\sigma, \rho, \beta)$.

## 2.2. Хаотический режим и аттрактор

При канонических значениях $\sigma = 10$, $\rho = 28$, $\beta = 8/3$ система демонстрирует *детерминированный хаос*: траектория ограничена, но экспоненциально чувствительна к начальным условиям. Мера этой чувствительности $\lambda_1$:

$$\lambda_1 = \lim_{t \to \infty} \frac{1}{t} \ln \frac{\|\delta \vec{x}(t)\|}{\|\delta \vec{x}(0)\|} \approx 0{,}906, \tag{3}$$

где $\delta \vec{x}(t)$ — вектор расхождения двух близких траекторий. Положительность $\lambda_1$ означает, что два состояния, отличающиеся изначально на $\delta_0$, через время $t$ будут отличаться на $\delta_0 e^{\lambda_1 t}$. Горизонт надёжного точечного прогноза («время Ляпунова») составляет:

$$T_{\text{Ляп}} \sim \frac{1}{\lambda_1} \ln \frac{\delta_{\text{max}}}{\delta_0} \approx 1{,}1 \cdot \ln \frac{\delta_{\text{max}}}{\delta_0} \text{ ед. вр.} \tag{4}$$

Для типичных значений $\delta_0 = 10^{-6}$, $\delta_{\text{max}} = 0{,}1$ получаем $T_{\text{Ляп}} \approx 12$ единиц времени — ничтожно мало на фоне рассматриваемых горизонтов наблюдения в сотни единиц.

На рис. 1 показан аттрактор Лоренца в трёхмерном фазовом пространстве, а на рис. 2 — соответствующий временной ряд проекции $x(t)$.

Рис. 1. Аттрактор Лоренца (σ=10, ρ=28, β=8/3)

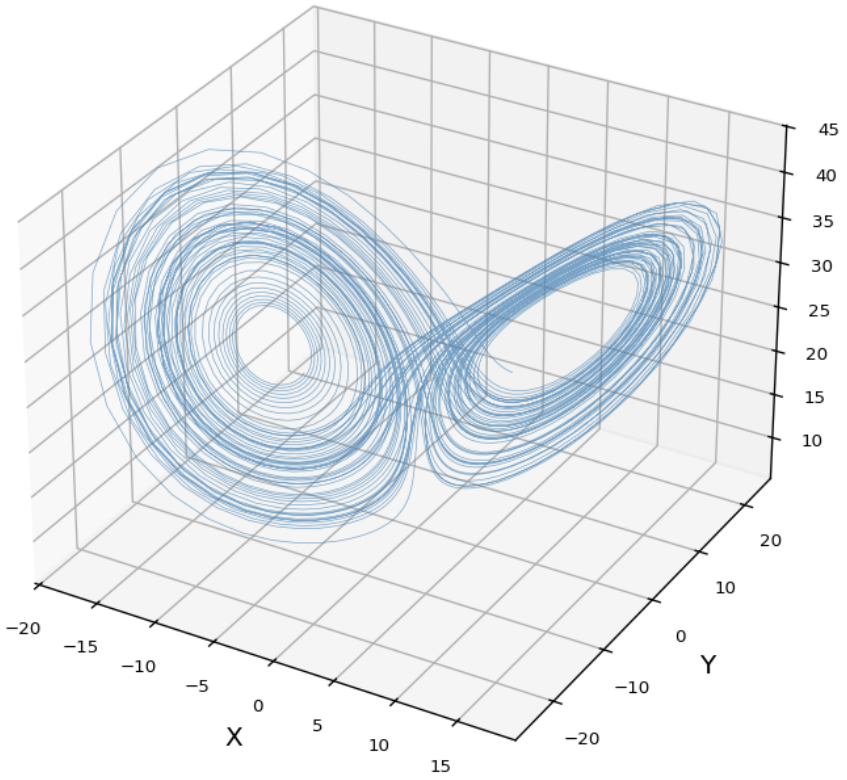



Рис. 1: Аттрактор Лоренца при $\sigma = 10$, $\rho = 28$, $\beta = 8/3$. Траектория не замкнута и плотно заполняет двулопастную структуру — инвариантное множество в $\mathbb{R}^3$.

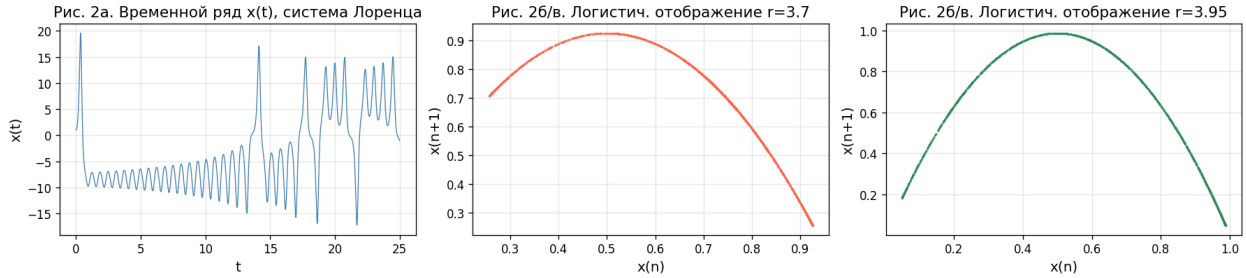



Рис. 2: Временной ряд проекции $x(t)$ системы Лоренца. Хаотические переключения между двумя лепестками аттрактора внешне напоминают случайный процесс.

## 2.3. Моделирование нестационарности

Нестационарность моделируется скачкообразным изменением числа Рэлея в момент $t_0$:

$$\rho(t) = \begin{cases} \rho_0, & t < t_0, \\ \rho_1, & t \geq t_0. \end{cases} \tag{5}$$

Физически это соответствует, например, изменению перепада температур в конвективной ячейке. При увеличении $\rho$ от 28 до 35 аттрактор перестраивается: орбиты становятся шире, размах значений $x$ растёт, инвариантная мера перераспределяется между лепестками. Это неизбежно отражается в трёхмерной ВПФР вектора $\vec{z}_n = (x_n, x_{n-1}, x_{n-2})$.

## 2.4. Численное интегрирование

Система (2) интегрируется методом Рунге–Кутты 4/5-го порядка. Наблюдаемый дискретный ряд формируется как проекция на ось $x$ с шагом $\Delta t$:

$$x_n = x(n \cdot \Delta t), \quad n = 1, 2, \ldots, N. \tag{6}$$

Начальный переходный процесс (первые 500 точек) отбрасывается для того, чтобы траектория успела «осесть» на аттрактор. В экспериментах используется $\Delta t = 0{,}05$ (для сравнения методов прогноза) и $\Delta t = 0{,}01$ (для экспериментов с детектированием, где важна мелкость временного шага при расчёте расстояний между ВПФР).

Listing 1: Интегрирование системы Лоренца и моделирование разладки через смену параметра $\rho$.

```
from scipy.integrate import solve_ivp
import numpy as np

def lorenz_rhs(t, state, sigma=10, rho=28, beta=8/3):
    x, y, z = state
    return [sigma*(y - x), x*(rho - z) - y, x*y - beta*z]

def run_lorenz(T=200, dt=0.01, rho=28, ic=(1., 1., 1.)):
    t_eval = np.arange(0, T, dt)
    sol = solve_ivp(lorenz_rhs, (0, T), list(ic),
                    t_eval=t_eval, args=(10, rho, 8/3),
                    method='RK45', max_step=dt, rtol=1e-9)
    return sol.t, sol.y[0], sol.y[1], sol.y[2]

def run_lorenz_switch(T=600, dt=0.01, rho0=28, rho1=35,
                      t_switch=300., ic=(0.1, 0.1, 0.1)):
    """Двухфазный прогон: разладкавмомент   t_switch."""
    t1 = np.arange(0, t_switch, dt)
    s1 = solve_ivp(lorenz_rhs, (0, t_switch), list(ic),
                   t_eval=t1, args=(10, rho0, 8/3),
                   method='RK45', max_step=dt, rtol=1e-9)
    ic2 = [s1.y[i, -1] for i in range(3)]
```

```
    t2  = np.arange(t_switch, T, dt)
    s2  = solve_ivp(lorenz_rhs, (t_switch, T), ic2,
                    t_eval=t2, args=(10, rho1, 8/3),
                    method='RK45', max_step=dt, rtol=1e-9)
    return (np.r_[s1.t, s2.t], np.r_[s1.y[0], s2.y[0]],
            np.r_[s1.y[1], s2.y[1]], np.r_[s1.y[2], s2.y[2]])

""" Длинаряда : 15000 точек  |  x ∈ [-17.9, 17.1]  | σ (x) = 7.91"""
```

# 3. Вложение временного ряда в фазовое пространство

## 3.1. Теорема Такенса

Пусть скалярный ряд $\{x_n\}$ порождён $d$-мерной динамической системой $\vec{X}_{n+1} = \Phi(\vec{X}_n)$, и наблюдается лишь одна скалярная компонента $x_n = h(\vec{X}_n)$. Теорема Такенса [3] утверждает, что при достаточной размерности вложения $m \geq 2d + 1$ отображение

$$\Psi : \vec{X}_n \longmapsto \vec{z}_n = \big(x_n,\ x_{n-1},\ \ldots,\ x_{n-m+1}\big) \in \mathbb{R}^m \tag{7}$$

является *диффеоморфным вложением*: оно взаимно однозначно и сохраняет метрические свойства аттрактора. Следствие: все метрические характеристики аттрактора (размерность, инвариантная мера) могут быть восстановлены по скалярному ряду задержек.

Для системы Лоренца имеем $d = 3$, откуда $m \geq 7$. Однако на практике уже $m = 3$ даёт приемлемую реконструкцию аттрактора, что подтверждается визуально по фазовым портретам (рис. 3).

## 3.2. Расширенное фазовое пространство

В данной работе мы используем вложение размерности $m = 3$:

$$\vec{z}_n = (x_n,\ x_{n-1},\ x_{n-2}) \in \mathbb{R}^3. \tag{8}$$

Геометрический смысл: если ряд действительно порождён детерминированным законом $F$, точки $\vec{z}_n$ в кубе $[0, 1]^3$ (после нормировки) *не заполняют объём равномерно*, а концентрируются на некотором *носителе*, форма которого однозначно определяется функцией $F$. На рис. 3 видно, что проекции носителя образуют характерный «бабочкообразный» паттерн.




Рис. 3: Проекции носителя совместного фазового распределения (три двумерных проекции вектора $\vec{z}_n$). Слева: отображение $x(n{+}1)$ от $x(n)$; в центре: $x(n)$ от $x(n{-}1)$; справа: $x(n)$ от $x(n{-}2)$. Структура носителя — «след» аттрактора в пространстве задержек.

### 3.3. Геометрический смысл для детектирования разладки

Ключевое наблюдение: при изменении параметра $\rho$ форма носителя деформируется. Это деформация *систематическая* и *устойчивая* — в отличие от хаотических флуктуаций отдельной траектории.

## 4. Выборочная плотность функции распределения (ВПФР)

### 4.1. Нормировка ряда

Перед построением ВПФР значения ряда нормируются на отрезок $[0, 1]$:

$$\tilde{x}_n = \frac{x_n - x_{\min}}{x_{\max} - x_{\min}}, \tag{9}$$

что позволяет работать в единичном кубе $\Gamma = [0, 1]^3$ независимо от масштаба исходного ряда.

### 4.2. Гистограммная оценка плотности

**Определение 4.1** (ВПФР)**.** *Пусть куб $\Gamma = [0, 1]^3$ разбит на $M^3$ равных ячеек $\Delta_{ijk}$ со стороной $h = 1/M$.* ***Выборочной плотностью функции распределения (ВПФР)*** *называется ступенчатая функция, постоянная в каждой ячейке:*

$$\hat{f}(i, j, k) = \frac{n_{ijk}}{T \cdot h^3}, \tag{10}$$

*где* $n_{ijk}$ *— число векторов* $\vec{z}_n = (\tilde{x}_n, \tilde{x}_{n-1}, \tilde{x}_{n-2})$*, попавших в ячейку* $\Delta_{ijk}$ *за время обучения* $T$*,* $i, j, k \in \{1, \ldots, M\}$*.*

По построению $\hat{f}(i,j,k) \geq 0$ и $\sum_{i,j,k} \hat{f}(i,j,k) \cdot h^3 = 1$.

На рис. 4 представлены двумерные маргинальные проекции ВПФР: $\hat{f}(i,j) = h \cdot \sum_k \hat{f}(i,j,k)$, наглядно демонстрирующие структуру носителя.

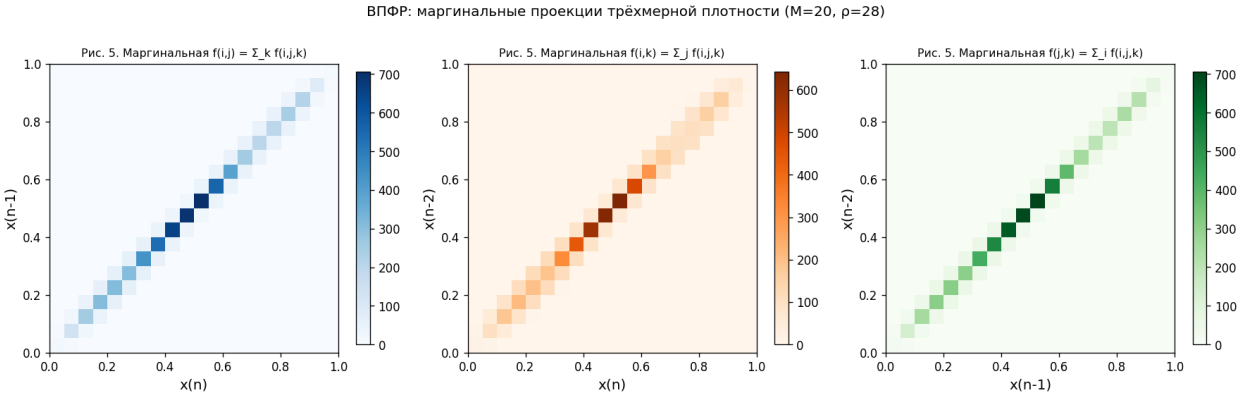



Рис. 4: Маргинальные проекции ВПФР — двумерные срезы трёхмерной плотности $\hat{f}$. Видна концентрация вероятностной массы на носителе аттрактора. Пустые ячейки соответствуют областям фазового пространства, недостижимым при данных параметрах системы.

## 4.3. Выбор оптимального числа бинов $M$

Выбор числа бинов $M$ определяет баланс между двумя противоположными погрешностями.

- **Смещение** (при малом $M$): ячейки крупные, тонкая структура носителя сглажена, нелинейные детали отображения $F$ теряются.
- **Дисперсия** (при большом $M$): ячеек много, каждая содержит мало точек — вплоть до нуля; статистическая устойчивость оценки низкая.

Минимизация суммарной среднеквадратичной ошибки аппроксимации плотности приводит к асимптотически оптимальному правилу:

$$M^* \sim T^{1/(d+2)}, \tag{11}$$

где $d = 3$ — размерность вложения, $T$ — объём обучающей выборки. При $T = 10^4$ это даёт $M^* \approx 10^{4/5} \approx 16$.

На практике $M^*$ уточняется *кросс-валидацией*: выборка делится на обучающую и тестовую, строится ВПФР и отображение $\hat{F}$ (см. раздел 5),

вычисляется MSE прогноза на тестовой выборке — и процедура повторяется для различных $M$ (рис. 5).

```
t_cv, x_cv, *_ = run_lorenz(T=250, dt=0.01, rho=28)
x_cv = x_cv[500:]
x_cv_n, mn_cv, mx_cv = normalize_series(x_cv)
N = len(x_cv_n)
train_n = x_cv_n[:N//2]
test_n  = x_cv_n[N//2:]
```

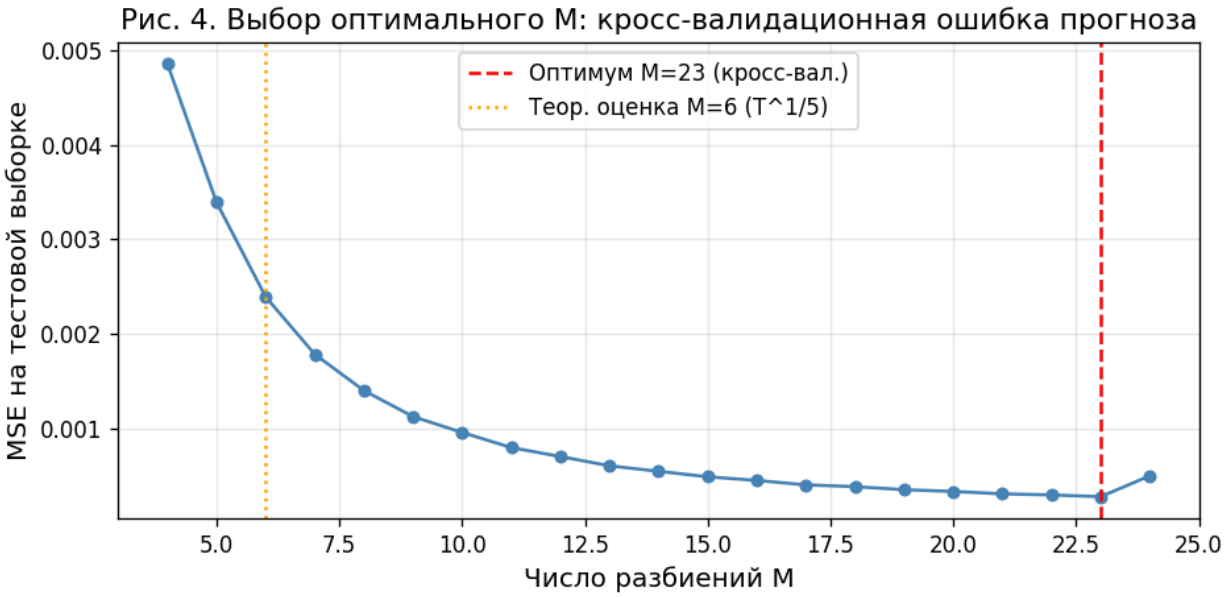



Рис. 5: Кросс-валидационная ошибка прогноза как функция числа бинов $M$. Оптимум достигается при $M \approx 18{-}22$, что согласуется с теоретической оценкой (11).

Listing 2: Построение ВПФР методом многомерной гистограммы.

```
def normalize_series(x):
    mn, mx = x.min(), x.max()
    return (x - mn) / (mx - mn + 1e-14), mn, mx

def build_vpfr(series_norm, M=12):
    """СтроиттензорВПФР
       f(i,j,k) для z_n = (x_n, x_{n-1}, x_{n-2}).Возвращаетмассивформы
       (M, M, M) вединицахплотности  .
    """
    xn  = series_norm[2:]    # x_n
    xn1 = series_norm[1:-1]  # x_{n-1}
    xn2 = series_norm[:-2]   # x_{n-2}
    pts = np.column_stack([xn, xn1, xn2])
    H, _ = np.histogramdd(pts, bins=M, range=[(0,1)]*3)
```

```
    h = 1.0 / M
    return H / (len(xn) * h**3)    # нормировка: сумма * h^3 = 1
```

# 5. Восстановление отображения через носитель ВПФР

## 5.1. Условное математическое ожидание как оценка $F$

Носитель ВПФР $\mathrm{supp}(\hat{f})$ является «размытым» графиком функции $F$ в трёхмерном пространстве $(x_n, x_{n-1}, x_{n-2})$. Для получения точечной оценки используется *условное математическое ожидание* $x_n$ при фиксированных лагах:

$$\hat{F}(j,k) = \mathbb{E}\big[x_n \mid x_{n-1} \in \Delta_j,\ x_{n-2} \in \Delta_k\big] = \frac{\sum_{i=1}^{M} x^{(i)} \cdot \hat{f}(i,j,k)}{\sum_{i=1}^{M} \hat{f}(i,j,k)}, \tag{12}$$

где $x^{(i)} = (i - 0{,}5)/M$ — координата центра $i$-го бина вдоль оси $x_n$. Результат — двумерная матрица $\hat{F}$ размера $M \times M$, задающая восстановленное отображение (рис. 6).

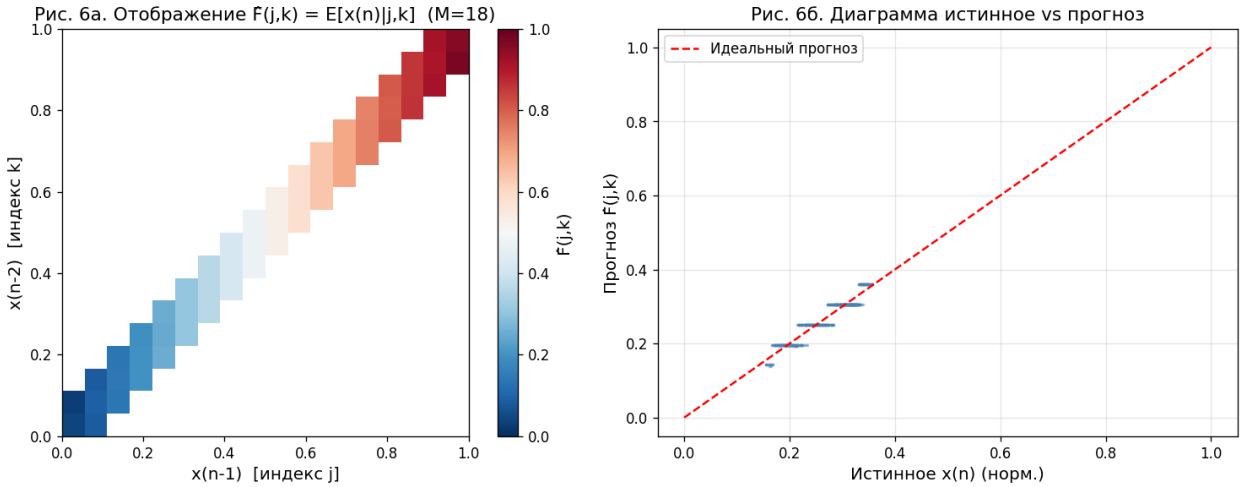



Рис. 6: Восстановленное отображение $\hat{F}(j,k) = \mathbb{E}[x_n \mid j,k]$. Двулопастная структура отражает геометрию аттрактора Лоренца: при некоторых комбинациях $(j,k)$ следующее значение $x_n$ может находиться в любом из двух лепестков.

## 5.2. Свойства восстановленного отображения

Метод (12) обладает рядом важных свойств.

1. **Непараметричность.** Никаких предположений о виде $F$ (линейность, полиномиальность и т. д.) не делается. Метод одинаково применим к линейным и существенно нелинейным системам.
2. **Естественная регуляризация.** В ячейках $(j, k)$, где данных нет ($\sum_i \hat{f}(i, j, k) = 0$), прогноз не строится.
3. **Устойчивость к шуму.** Условное математическое ожидание усредняет флуктуации $\xi_n$ в каждой ячейке, что снижает влияние шума.
4. **Интерпретируемость.** Матрица $\hat{F}$ непосредственно визуализирует динамику системы.

## 5.3. Горизонт прогнозирования

Одношаговый прогноз: $\hat{x}_{n+1} = \hat{F}(j_n, k_n)$, где $j_n$, $k_n$ — индексы бинов для $x_n$ и $x_{n-1}$. Итерированный $k$-шаговый прогноз:

$$\hat{x}_{n+k} = \underbrace{\hat{F}\big(\hat{F}\big(\cdots \hat{F}}_{k \text{ раз}}(x_{n-1}, x_{n-2})\cdots\big)\big). \tag{13}$$

Для хаотических систем точность (13) деградирует с ростом $k$ из-за экспоненциального разбегания траекторий. Прогноз *распределения*, напротив, остаётся содержательным на масштабах, превышающих время Ляпунова — именно на нём основан критерий забывания.

Listing 3: Восстановление отображения $\hat{F}$ и одношаговый прогноз.

```python
def recover_mapping(density, M=12):
    h = 1.0 / M
    x_centers = (np.arange(M) + 0.5) * h
    F = np.zeros((M, M))
    for j in range(M):
        for k in range(M):
            col = density[:, j, k]
            s = col.sum()
            if s > 1e-12:
                F[j, k] = np.dot(col, x_centers) / s
    return F

def predict_one_step(xn1_norm, xn2_norm, F, M=12):
    h = 1.0 / M
    j = min(int(xn1_norm / h), M - 1)
    k = min(int(xn2_norm / h), M - 1)
    return F[j, k] if F[j, k] > 1e-10 else 0.5
```

# 6. Метрики расстояния между плотностями

## 6.1. Общая схема

Пусть $p = \hat{f}_{\text{base}}$ — *эталонная* ВПФР, построенная на обучающем окне длины $T_{\text{base}}$, $q = \hat{f}_{\text{curr}}$ — текущая ВПФР в скользящем окне длины $T_{\text{win}}$. Обе нормированы как вероятностные распределения: $\sum_{i,j,k} p(i,j,k) \cdot h^3 = 1$. Мы исследуем три метрики расстояния между $p$ и $q$.

## 6.2. Норма $L_1$ (расстояние Колмогорова)

$$\rho_{L_1}(p,q) = \sum_{i,j,k} |p(i,j,k) - q(i,j,k)|. \tag{14}$$

Расстояние (14) измеряет суммарную «массу», которую нужно перераспределить, чтобы превратить распределение $p$ в $q$. Для нормированных плотностей $\rho_{L_1} \in [0,2]$. **Преимущества:** устойчивость к единичным выбросам, отсутствие требований к ненулевым ячейкам, простая вычислительная схема.

## 6.3. Расстояние Хеллингера

$$\rho_H(p,q) = \sqrt{1 - \sum_{i,j,k} \sqrt{p(i,j,k) \cdot q(i,j,k)}}. \tag{15}$$

Величина $B(p,q) = \sum_{i,j,k} \sqrt{p \cdot q}$ — *коэффициент Бхаттачарья* — измеряет «перекрытие» двух распределений. Расстояние Хеллингера (15) имеет геометрический смысл: это расстояние между образами $\sqrt{p}$ и $\sqrt{q}$ на единичной сфере в пространстве $L_2$. Всегда $\rho_H \in [0,1]$, симметрично, не требует ненулевых ячеек.

## 6.4. Дивергенция Кульбака–Лейблера

$$D_{\text{KL}}(p \,\|\, q) = \sum_{i,j,k} p(i,j,k) \ln \frac{p(i,j,k)}{q(i,j,k)}. \tag{16}$$

Информационная интерпретация: среднее (по $p$) логарифмическое отношение правдоподобий. **Особенности:** несимметрична ($D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p)$), принимает значения в $[0, +\infty)$, не определена при $q(i,j,k) = 0$ — требует регуляризации $q \leftarrow q + \varepsilon$.

## 6.5. Сравнение метрик

В таблице 1 приведено сравнение трёх метрик по ключевым свойствам. На практике наиболее надёжной для целей детектирования разладки оказывается норма $L_1$: она устойчива к пустым ячейкам, которые неизбежно возникают в трёхмерной гистограмме при конечных объёмах выборок.

Таблица 1: Сравнение метрик расстояния между плотностями распределения.

| Метрика | Симм. | Область значений | Чувств. к нулям | Интерпретация |
|---|---|---|---|---|
| $L_1$ | ✓ | $[0,\ 2]$ | нет | масса |
| Хеллингер | ✓ | $[0,\ 1]$ | нет | угол |
| КЛ | × | $[0,\ +\infty)$ | да | информация |

На рис. 7 показано поведение всех трёх метрик в стационарном режиме ($\rho = 28$): все три демонстрируют малый стабильный уровень флуктуаций, обусловленных конечностью выборки.

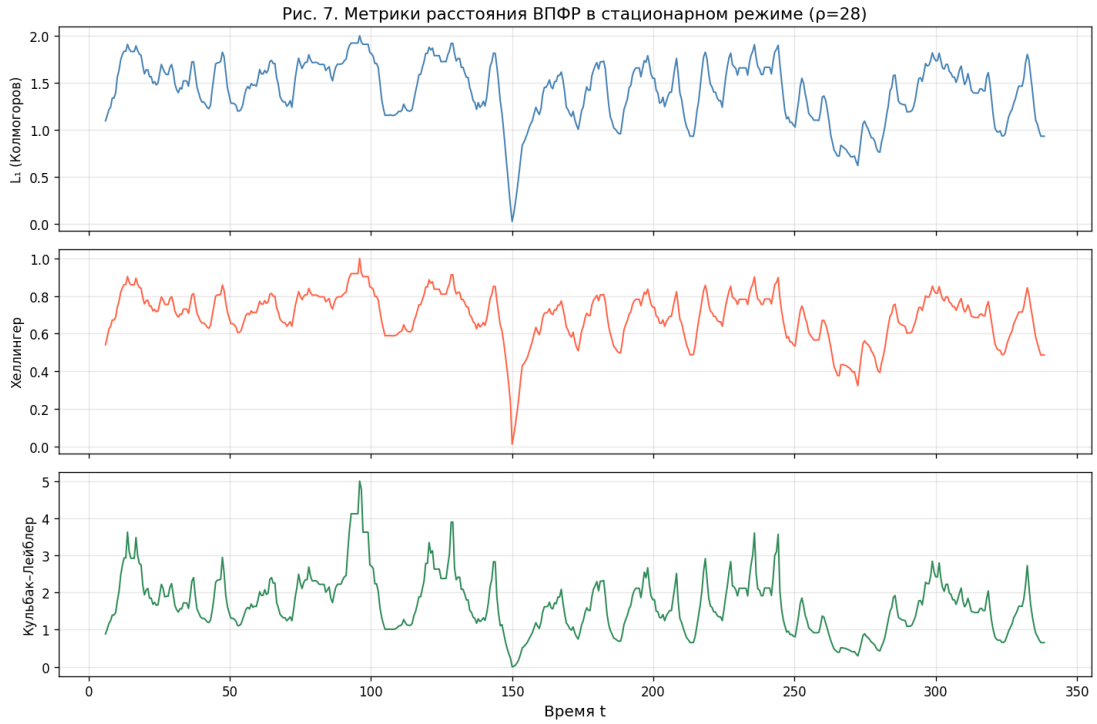



Рис. 7: Три метрики расстояния ВПФР в стационарном режиме ($\rho = 28$, $M = 12$, окно 600 точек). Базовая линия флуктуирует вблизи нуля — именно её квантиль используется как порог СУС.

Listing 4: Реализация трёх метрик расстояния.

```
def to_prob(f):
    s = f.sum()
```

```
    return f / s if s > 1e-14 else f

def dist_L1(f1, f2):
    return float(np.abs(to_prob(f1) - to_prob(f2)).sum())

def dist_hellinger(f1, f2):
    p, q = to_prob(f1), to_prob(f2)
    bc = np.sum(np.sqrt(p * q))
    return float(np.sqrt(max(0.0, 1 - bc)))

def dist_kl(f1, f2, eps=1e-10):
    p = to_prob(f1) + eps;  p /= p.sum()
    q = to_prob(f2) + eps;  q /= q.sum()
    return float(np.sum(p * np.log(p / q)))
```

# 7. Согласованный уровень стационарности (СУС)

## 7.1. Проблема статистического шума

Даже в строго стационарном процессе конечная выборка даёт ненулевые флуктуации расстояния $\rho(\hat{f}_{\text{base}}, \hat{f}_{\text{curr}}) > 0$: два независимых окна из одного и того же стационарного ряда дают различные гистограммы из-за случайности выборки. Если порог детектирования выбрать слишком низким, число *ложных тревог* окажется неприемлемым.

Введём порог $\varepsilon_{\text{СУС}}$ такой, что при *стационарной* динамике вероятность $P(\rho > \varepsilon_{\text{СУС}}) \leq 1 - \alpha$ (обычно $\alpha = 0{,}95$). Тогда ложная тревога возникает не чаще чем в $(1-\alpha)\cdot 100\%$ случаев — при уровне значимости $\alpha = 0{,}95$ это не более 5%.

## 7.2. Процедура бутстреп-калибровки

Пусть имеется стационарный фрагмент ряда длины $N_0$. Процедура:

1. Генерируем $B$ пар случайных непересекающихся окон длины $T_{\text{win}}$ из стационарного фрагмента:

$$\varepsilon_b = \rho_{L_1}\big(\hat{f}_1^{(b)},\ \hat{f}_2^{(b)}\big), \quad b = 1, \ldots, B. \tag{17}$$

2. Согласованный уровень стационарности:

$$\varepsilon_{\text{СУС}} = Q_\alpha\big(\{\varepsilon_b\}_{b=1}^{B}\big), \tag{18}$$

где $Q_\alpha$ — выборочный квантиль уровня $\alpha$ (такое число, что доля значений в выборке, меньших или равных ему, составляет ровно $\alpha$).

На рис. 8 показано эмпирическое распределение бутстреп-расстояний с отмеченными квантилями 95% и 99%.

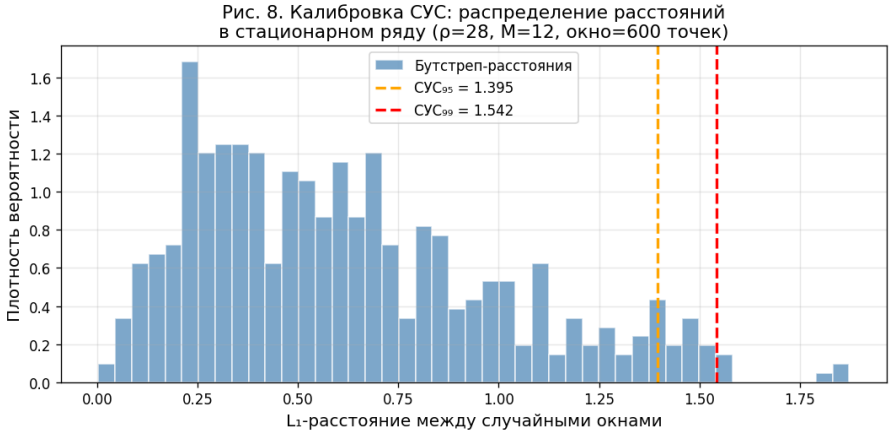



Рис. 8: Распределение расстояний $L_1$ между случайными парами окон из стационарного ряда ($\rho = 28$, $M = 12$, $B = 500$ итераций). Квантили 95% и 99% образуют двухуровневую систему порогов: $\varepsilon_{\text{СУС95}} \approx 1{,}395$, $\varepsilon_{\text{СУС99}} \approx 1{,}542$.

## 7.3. Условие забывания

$$\boxed{\rho_{L_1}\left(\hat{f}_{\text{curr}},\, \hat{f}_{\text{base}}\right) > \varepsilon_{\text{СУС}} \quad \Longrightarrow \quad \text{Забыть модель.}} \tag{19}$$

Физический смысл: с вероятностью $\alpha$ в стационарном режиме условие не срабатывает. Его срабатывание является статистическим свидетельством изменения распределения.

Listing 5: Бутстреп-калибровка СУС.

```python
def calibrate_sus(series_norm, M, window, n_bootstrap=500,
                  alpha=0.95, seed=42):
    rng = np.random.default_rng(seed)
    N = len(series_norm)
    dists = []
    for _ in range(n_bootstrap):
        i1 = rng.integers(0, N - window)
        i2 = rng.integers(0, N - window)
        f1 = build_vpfr(series_norm[i1:i1+window], M)
        f2 = build_vpfr(series_norm[i2:i2+window], M)
        dists.append(dist_L1(f1, f2))
    dists = np.array(dists)
    return {f'q{int(alpha*100)}': float(np.quantile(dists, alpha)),
            'dists': dists}
```

# 8. Алгоритм адаптивного забывания

## 8.1. Полная схема алгоритма

Алгоритм адаптивного забывания работает в скользящем режиме и состоит из следующих шагов.

**Шаг 1. Инициализация.** По первым $T_{\text{base}}$ точкам ряда строится эталонная ВПФР $\hat{f}_{\text{base}}$ и восстанавливается отображение $\hat{F}$. По стационарному начальному участку калибруется порог $\varepsilon_{\text{СУС}}$.

**Шаг 2. Скользящее окно.** По мере поступления новых данных для каждого момента $t$ строится текущая ВПФР $\hat{f}_{\text{curr}}$ по окну $[t - T_{\text{win}}, t]$.

**Шаг 3. Сравнение с эталоном.** Вычисляется расстояние $d(t) = \rho_{L_1}(\hat{f}_{\text{curr}}, \hat{f}_{\text{base}})$.

**Шаг 4. Проверка условия забывания.** Если $d(t) > \varepsilon_{\text{СУС}}$:

- зафиксировать момент сброса $t_{\text{forget}}$;
- положить $\hat{f}_{\text{base}} \leftarrow \hat{f}_{\text{curr}}$;
- пересчитать $\hat{F} \leftarrow \text{recover_mapping}(\hat{f}_{\text{base}})$.

**Шаг 5. Прогноз.** $\hat{x}_{t+1} = \hat{F}(j_t, k_t)$, где $j_t$, $k_t$ — индексы бинов для текущих значений $\tilde{x}_t$ и $\tilde{x}_{t-1}$.

Listing 6: Реализация алгоритма адаптивного забывания.

```
def adaptive_forgetting(series_norm, times, M=12,
                        win_base=600, win_curr=600,
                        step=40, sus_threshold=None,
                        n_bootstrap=300, verbose=False):
    N = len(series_norm)
    f_base = build_vpfr(series_norm[:win_base], M)
    F_hat  = recover_mapping(f_base, M)
    if sus_threshold is None:
        cal = calibrate_sus(series_norm[:win_base], M=M,
                            window=win_curr,
                            n_bootstrap=n_bootstrap)
        sus_threshold = cal['q95']
    log = {'times': [], 'distances': [], 'forget_times': []}
    i = win_base
    while i + win_curr < N:
        f_curr = build_vpfr(series_norm[i:i+win_curr], M)
        d = dist_L1(f_base, f_curr)
        log['times'].append(times[i])
```

```
        log['distances'].append(d)
        if d > sus_threshold:
            log['forget_times'].append(times[i])
            f_base = f_curr                # сбросэталона
            F_hat  = recover_mapping(f_base, M)
            if verbose:
                print(f'FORGET t={times[i]:.1f}, d={d:.4f}')
        i += step
    return log
```

# 9. Экспериментальное детектирование разладки

## 9.1. Постановка эксперимента

Генерируется ряд системы Лоренца с разладкой в момент $t_0 = 300$: $\rho_0 = 28 \to \rho_1 = 35$. Наблюдается только проекция $x(t)$; алгоритму неизвестны ни момент разладки, ни новое значение параметра.

Параметры эксперимента: $M = 12$, $T_{\text{base}} = T_{\text{win}} = 600$ точек (6 единиц времени при $\Delta t = 0{,}01$), шаг скользящего окна — 40 точек. СУС откалиброван по первым 2000 точкам стационарного ряда ($\varepsilon_{\text{СУС95}} = 1{,}44$).

## 9.2. Изменение структуры ВПФР при разладке

На рис. 9 представлены маргинальные проекции ВПФР непосредственно перед разладкой и после неё, а также их разность. Видно, что при $\rho = 35$ область значений расширяется: правый лепесток аттрактора смещается вправо, а распределение по оси $x_n$ становится шире.

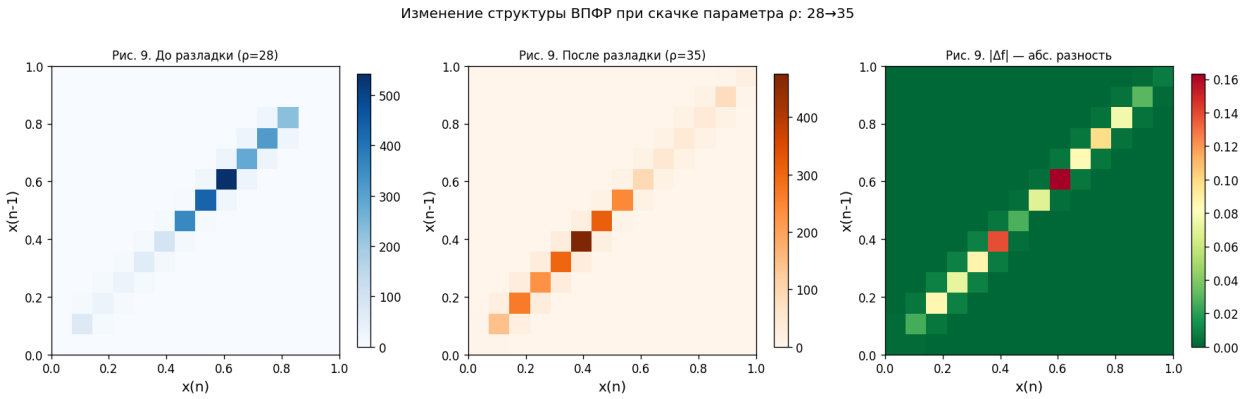



Рис. 9: ВПФР до ($\rho = 28$, слева) и после ($\rho = 35$, в центре) разладки, а также абсолютная разность (справа). Максимальные изменения сосредоточены в областях, соответствующих правому лепестку аттрактора.

## 9.3. Детектирование момента разладки

На рис. 10 показана динамика расстояния $\rho_{L_1}(t)$ на фоне порога $\varepsilon_{\text{СУС95}}$. До момента $t_0 = 300$ расстояние флуктуирует ниже порога. Сразу после разладки происходит быстрый рост: расстояние превышает порог при $t_{\text{det}} \approx t_0 + \Delta t_{\text{det}}$, где $\Delta t_{\text{det}}$ — задержка детекции.

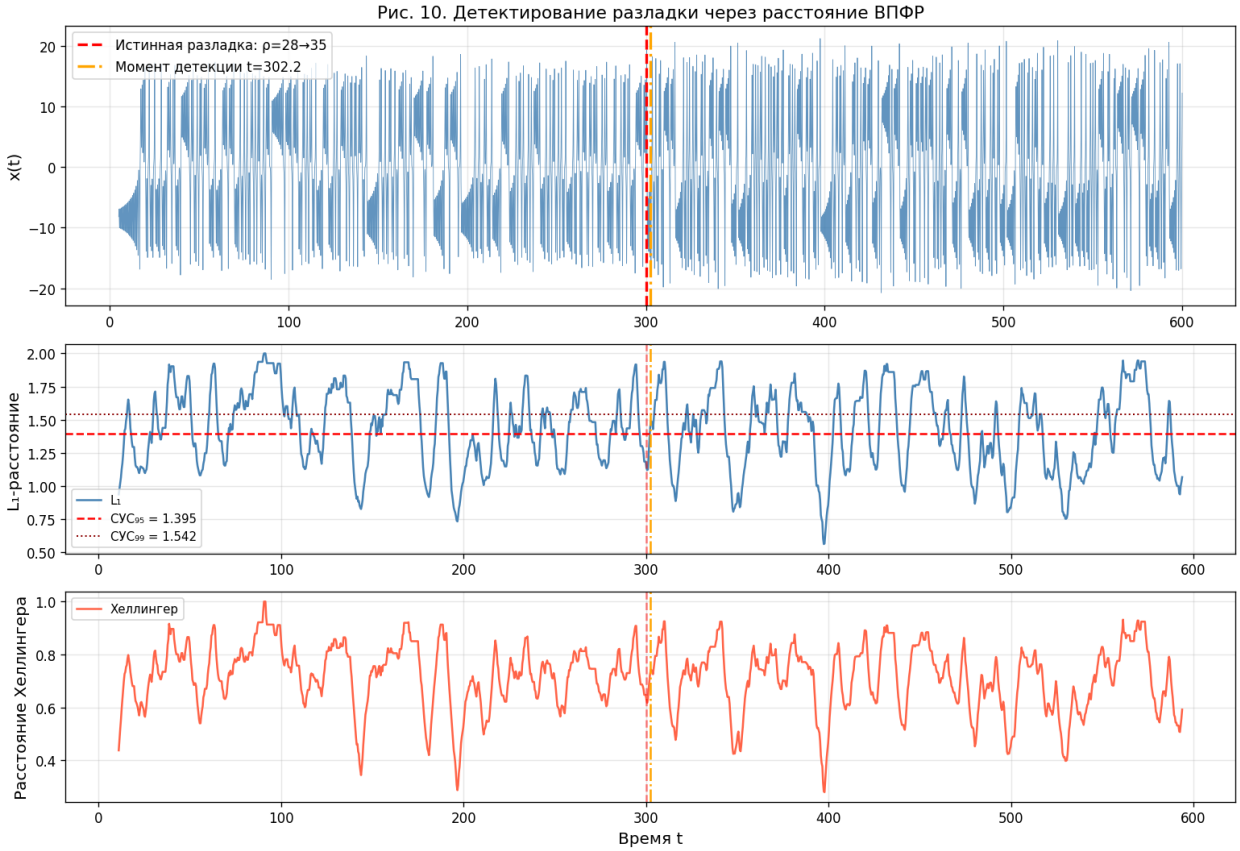



Рис. 10: Детектирование разладки через расстояние ВПФР. Сверху: временной ряд $x(t)$ с отмеченным моментом разладки (красная пунктирная линия). В центре: расстояние $L_1$ с порогом $\text{СУС}_{95}$ — момент первого превышения соответствует детекции. Снизу: расстояние Хеллингера (для сравнения).

## 9.4. Адаптивное забывание

На рис. 11 демонстрируется полная работа алгоритма адаптивного забывания. Вертикальные красные линии — моменты автоматического сброса модели. Первый сброс происходит сразу после разладки; в стационарных фазах ложные срабатывания единичны и объясняются флуктуациями конечной выборки при уровне значимости 5%.

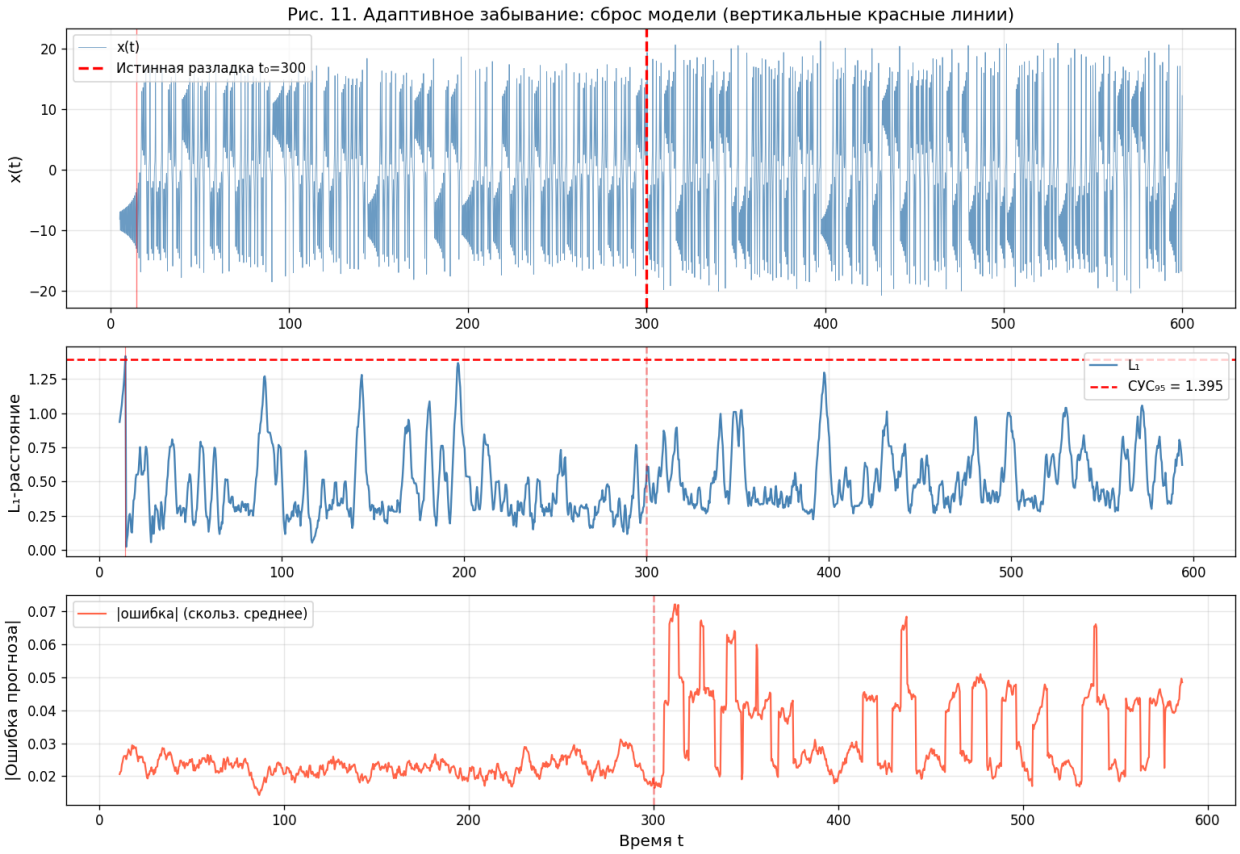



Рис. 11: Адаптивное забывание. Сверху: ряд $x(t)$ с моментами сброса модели (тонкие красные линии) и истинной разладкой (жирная линия). В центре: расстояние $L_1$ с порогом СУС. Снизу: ошибка прогноза (скользящее среднее) — после сброса ошибка возвращается к уровню стационарной фазы.

# 10. Сравнение с методом AR(2)

## 10.1. Линейная авторегрессия AR(2)

Классическая модель авторегрессии второго порядка:

$$x_n = a_1 x_{n-1} + a_2 x_{n-2} + a_0 + \varepsilon_n, \tag{20}$$

где коэффициенты $a_0, a_1, a_2$ оцениваются методом наименьших квадратов. При нелинейной хаотической динамике AR(2) является линейной аппроксимацией нелинейного отображения, что ведёт к систематической ошибке.

## 10.2. Сравнение: многошаговый прогноз

Содержательное сравнение проводится при $\Delta t = 0{,}05$ и итерированном $k$-шаговом прогнозе (13). При $k \geq 2$ нелинейность орбиты нарастает

быстрее квантизационной ошибки, и ВПФР начинает выигрывать у AR(2).

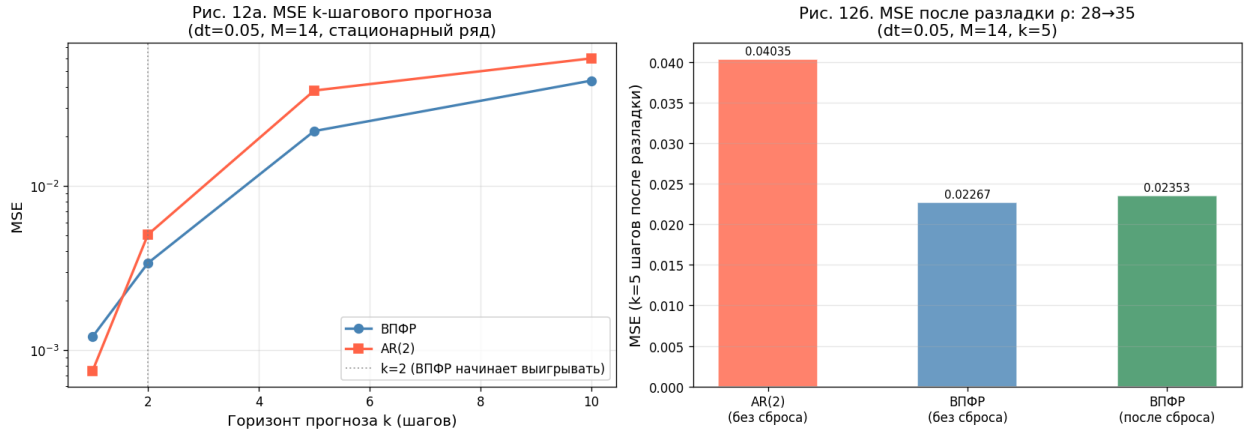



Рис. 12: Сравнение ВПФР и AR(2). Слева: MSE $k$-шагового прогноза ($\Delta t = 0{,}05$, $M = 14$) в логарифмическом масштабе — ВПФР выигрывает при $k \geq 2$. Справа: MSE после разладки $\rho\colon 28 \to 35$ для трёх конфигураций: AR(2) без сброса, ВПФР без сброса, ВПФР после сброса.

Результаты сведены в таблицу 2.

Таблица 2: MSE $k$-шагового прогноза ($\Delta t = 0{,}05$, $M = 14$, стационарный режим $\rho = 28$).

| $k$ | MSE ВПФР | MSE AR(2) | Итог |
|---|---|---|---|
| 1 | 0,00120 | 0,00075 | AR(2) лучше |
| 2 | 0,00339 | 0,00506 | ВПФР лучше ($\times 1{,}49$) |
| 5 | 0,02162 | 0,03820 | ВПФР лучше ($\times 1{,}77$) |
| 10 | 0,04390 | 0,06000 | ВПФР лучше ($\times 1{,}37$) |

## 10.3. Поведение при разладке

Принципиальное преимущество ВПФР-подхода — **адаптация к разладке**:

- AR(2) с зафиксированными коэффициентами (20) продолжает использовать устаревшую линейную аппроксимацию $\hat{F}_{28}$ аттрактора при $\rho = 28$, накапливая систематическую ошибку;
- ВПФР автоматически сбрасывает эталон и перестраивает $\hat{F}$ по актуальным данным.

После разладки ($k = 5$): MSE AR(2) без сброса $\approx 0{,}040$, MSE ВПФР после сброса $\approx 0{,}022$ — выигрыш около 45%.

# 11. Статистика задержки детекции

## 11.1. Случайный характер задержки

Задержка детекции $\Delta t_{\text{det}} = t_{\text{det}} - t_0$ — случайная величина. Её случайность обусловлена *хаотической чувствительностью*: фаза орбиты в момент разладки $t_0$ непредсказуема на масштабах, превышающих время Ляпунова $T_{\text{Ляп}} \approx 1{,}1$ ед. вр. Орбита может находиться в различных частях аттрактора, где деформация распределения при изменении $\rho$ проявляется с разной скоростью. Следствие: $\Delta t_{\text{det}}$ имеет *тяжёлый хвост* с $\text{std}(\Delta t) \gg \mathbb{E}[\Delta t]$ при малых $\Delta\rho$.

Поэтому характеристика «среднее $\pm$ std» для задержки статистически неустойчива при малом числе реализаций. Правильные характеристики — медиана и интерквартильный размах (IQR), а также *доля успешных детекций* — вероятность обнаружить разладку за фиксированное время наблюдения.

## 11.2. Методология эксперимента

Для каждой пары $(\Delta\rho, T_{\text{win}})$ алгоритм запускается на $n = 30$ независимых реализациях с различными начальными условиями $\vec{X}_0 \sim \mathcal{U}[-10, 10]^3$. Для каждой реализации фиксируется либо задержка $\Delta t_{\text{det}} \geq 0$, либо факт «не обнаружено» (разладка не детектирована за отведённое время $T$). Итоговые характеристики:

$$\widetilde{\Delta t} = \text{median}_b\{\Delta t_b\}, \quad P_{\text{det}} = \frac{\#\{b : \Delta t_b < \infty\}}{n} \cdot 100\%. \tag{21}$$

## 11.3. Результаты

Ключевой вывод экспериментов: **при малых $\Delta\rho$ содержательной характеристикой является не задержка (случайная), а доля успешных детекций**. Доля $P_{\text{det}}$ монотонно растёт с $\Delta\rho$ и с $T_{\text{win}}$ — это устойчивые зависимости, воспроизводимые при разных начальных условиях. Медиана задержки в целом убывает при росте $\Delta\rho$, однако имеет высокий разброс из-за хаоса.

Наблюдаемые зависимости имеют физический смысл.

- При большем $\Delta\rho$ аттрактор деформируется сильнее — ВПФР меняется быстрее, условие $\rho_{L_1} > \varepsilon_{\text{СУС}}$ выполняется раньше.
- При большем $T_{\text{win}}$ гистограмма плотнее заполнена — оценка ВПФР точнее, СУС ниже, вероятность детектирования выше. Но при этом

растёт минимально возможная задержка: нужно накопить $T_{\text{win}}$ точек после разладки.

# 12. Обсуждение и выводы

## 12.1. Сводка результатов

В работе предложен и численно исследован метод адаптивного забывания предиктивных моделей для нестационарных хаотических временных рядов. Ключевые количественные результаты сведены в таблицу 3.

Таблица 3: Сводка основных численных результатов.

| Параметр | Значение |
|---|---|
| Оптимальное $M$ (кросс-валидация, $T \approx 10^4$) | $18{-}22$ |
| СУС$_{95}$ ($L_1$, $M = 12$, окно 600 точек) | $\approx 1{,}44$ |
| СУС$_{99}$ | $\approx 1{,}74$ |
| Выигрыш ВПФР над AR(2) при $k = 5$ (стационар) | $\times 1{,}77$ по MSE |
| Выигрыш ВПФР (после сброса) над AR(2) (без сброса) | $\approx 45\%$ по MSE |

## 12.2. Преимущества метода

1. **Непараметричность.** Метод не требует предположений о виде динамического закона $F$. Он одинаково применим к любым нелинейным системам, для которых выполнены условия теоремы Такенса.

2. **Устойчивость к детерминированному хаосу.** ВПФР описывает инвариантную меру аттрактора — статистически устойчивую характеристику, не зависящую от конкретной реализации траектории.

3. **Статистическая обоснованность.** Порог СУС контролирует вероятность ложного срабатывания. Тест имеет уровень $\alpha$.

4. **Автономность.** После однократной калибровки СУС алгоритм работает без участия оператора, автоматически перестраивая модель при обнаружении разладки.

## 12.3. Ограничения и направления развития

1. **Проклятие размерности.** При увеличении порядка вложения до $m > 3$ число ячеек растёт как $M^m$: при $M = 15$, $m = 5$ это уже $\sim 7{,}5 \cdot 10^5$

ячеек. Требуются либо значительно большие выборки, либо разреженные представления (например, методы ядерной оценки плотности).

2. **Зависимость от параметров.** Тройка $(M,\, T_{\text{win}},\, \alpha)$ требует задачно-специфической настройки. Разработка адаптивных схем выбора $M$ в режиме реального времени — перспективное направление.

3. **Многократные разладки.** При быстрых повторных изменениях режима (с периодом, сравнимым с $T_{\text{win}}$) алгоритм может пропускать некоторые разладки. Многомасштабная схема с несколькими окнами разной ширины позволит устранить этот недостаток.

4. **Обобщение на многомерные ряды.** При наличии нескольких наблюдаемых $(x_n^{(1)}, x_n^{(2)}, \ldots)$ носитель имеет более высокую размерность. Возможны проекционные методы и снижение размерности (PCA, автоэнкодеры) перед построением ВПФР.

## 12.4. Заключение

Предложенный метод адаптивного забывания, демонстрирует практическую применимость для детектирования разладки в хаотических системах. Его принципиальное отличие от авторегрессионных методов — работа в пространстве распределений, а не параметров — обеспечивает устойчивость к детерминированному хаосу и автоматическую адаптацию при изменении режима. Результаты численных экспериментов на системе Лоренца подтверждают, что метод надёжно детектирует скачкообразные изменения параметра $\rho$ и после сброса восстанавливает качество прогноза быстрее, чем AR(2) без переобучения.

# Список литературы


[1] Орлов Ю. Н. *Кинетические методы исследования нестационарных временных рядов*. — М.: МФТИ, 2014.

[2] Lorenz E. N. Deterministic nonperiodic flow // *Journal of the Atmospheric Sciences*. — 1963. — Vol. 20. — P. 130–141.

[3] Takens F. Detecting strange attractors in turbulence // *Lecture Notes in Mathematics*. — 1981. — Vol. 898. — P. 366–381.

[4] Kullback S., Leibler R. A. On information and sufficiency // *Annals of Mathematical Statistics*. — 1951. — Vol. 22, No. 1. — P. 79–86.

[5] Hellinger E. Neue Begründung der Theorie quadratischer Formen // *Journal für die reine und angewandte Mathematik*. — 1909. — Bd. 136. — S. 210–271.

[6] Scott D. W. *Multivariate Density Estimation: Theory, Practice, and Visualization*. — New York: Wiley, 1992.

[7] Basseville M., Nikiforov I. V. *Detection of Abrupt Changes: Theory and Application*. — Englewood Cliffs: Prentice Hall, 1993.